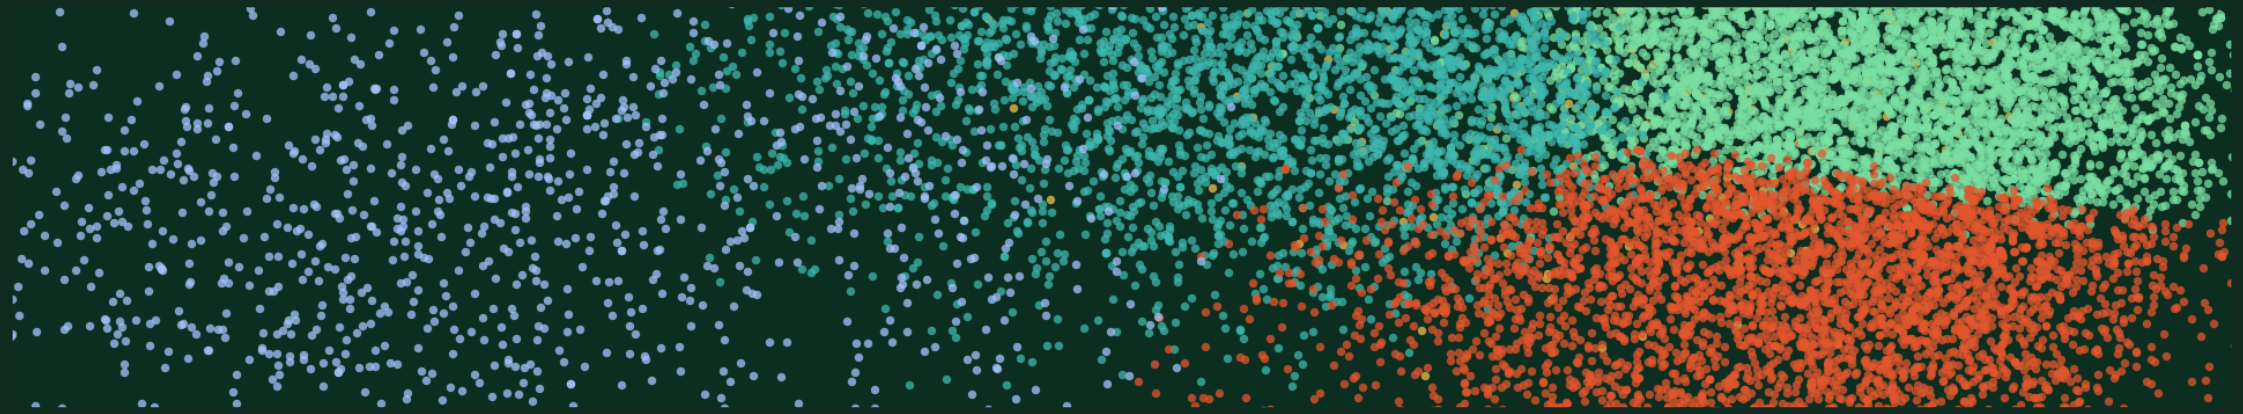
UANL · FCFM · MINERÍA DE DATOS · GRUPO 032

Minería de Datos aplicada a Spotify

Segmentación, popularidad, género musical y reglas de asociación



Luis Aguilar · Yael García · Natalíe González · Axel Verastegui · Jaime Zermeño

Introducción y objetivo

788 M

usuarios activos al mes en Spotify (3.er trimestre de 2026)

306 M

suscriptores Premium: cada reproducción genera datos

Objetivo: aplicar minería de datos al catálogo de canciones para segmentarlo, predecir su popularidad, clasificar su género y encontrar reglas de asociación.

¿Por qué elegimos Spotify?

Datos ricos

114,000 canciones, 114 géneros y 21 columnas, entre ellas 9 características de audio.

Cuatro técnicas

Un mismo conjunto permite agrupamiento, regresión, clasificación y asociación.

Preguntas reales

Recomendar música, anticipar éxitos y etiquetar canciones son problemas de negocio de cualquier plataforma.

Caso de estudio: cuatro problemas

1. Segmentación

¿Qué canciones suenan parecido? **K-Means + PCA**

2. Popularidad

¿Se puede predecir el puntaje de 0 a 100? **Random Forest y Gradient Boosting**

3. Género

¿Se reconoce el género por cómo suena? **Random Forest y SVM**

4. Asociación

¿Qué rasgos acompañan a la popularidad alta? **Apriori**

Proceso de minería de datos

1. Datos
114,000 registros, 21 columnas, CSV de Spotify

2. Limpieza
113,836 registros y 89,578 canciones distintas

3. Exploración
Distribuciones, correlaciones y popularidad por género

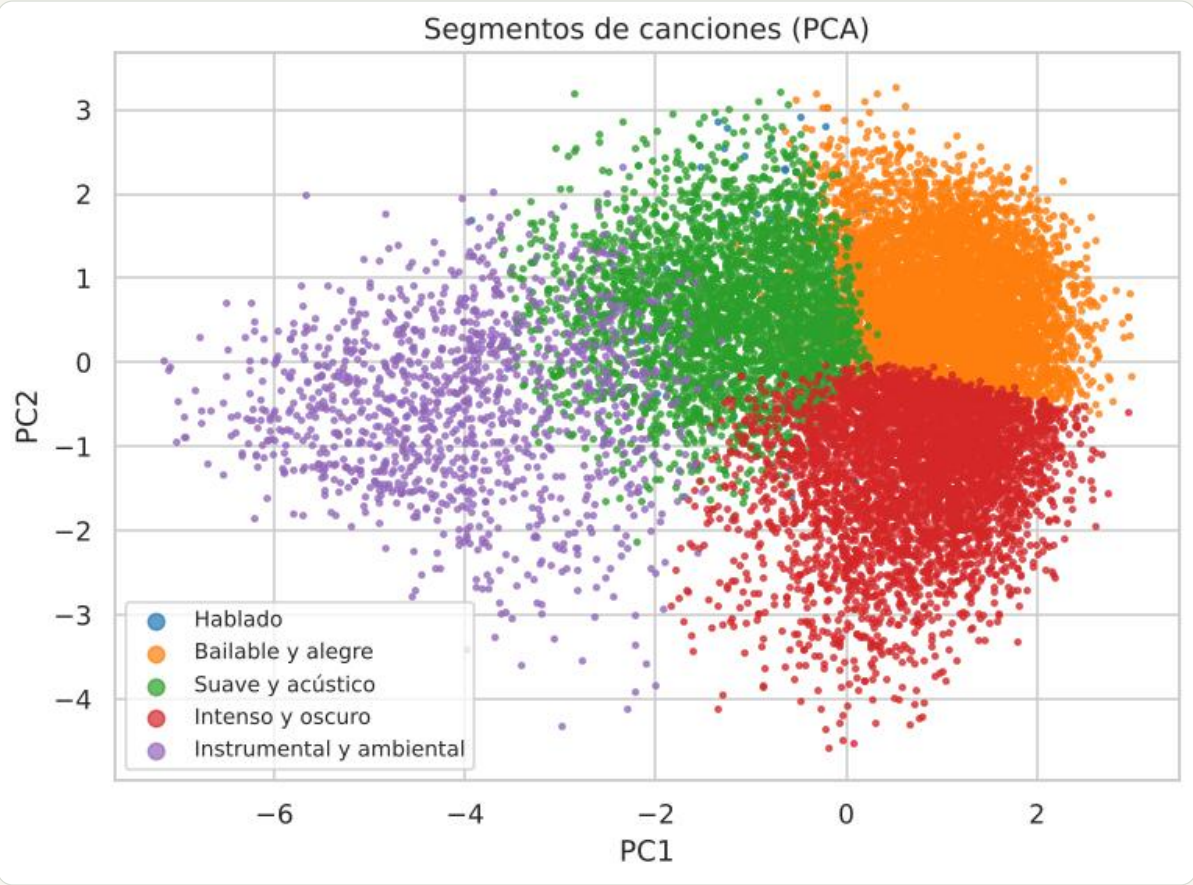
4. Modelado
Los cuatro análisis

5. Evaluación
Métricas y comparación contra un modelo base

Limpieza: se eliminaron 164 registros con nulos o mediciones inválidas (tempo, compás o duración en 0). Había 24,259 *track_id* repetidos, porque una canción aparece en varios géneros.

Herramientas: Python, Jupyter Notebook, pandas, scikit-learn, Matplotlib y seaborn.

Análisis 1: cinco segmentos de canciones



K-Means con k = 5 sobre 9 variables de audio estandarizadas; PCA explica 47.9% de la varianza.

Bailable y alegre · 37.7%

Intenso y oscuro · 29.9%

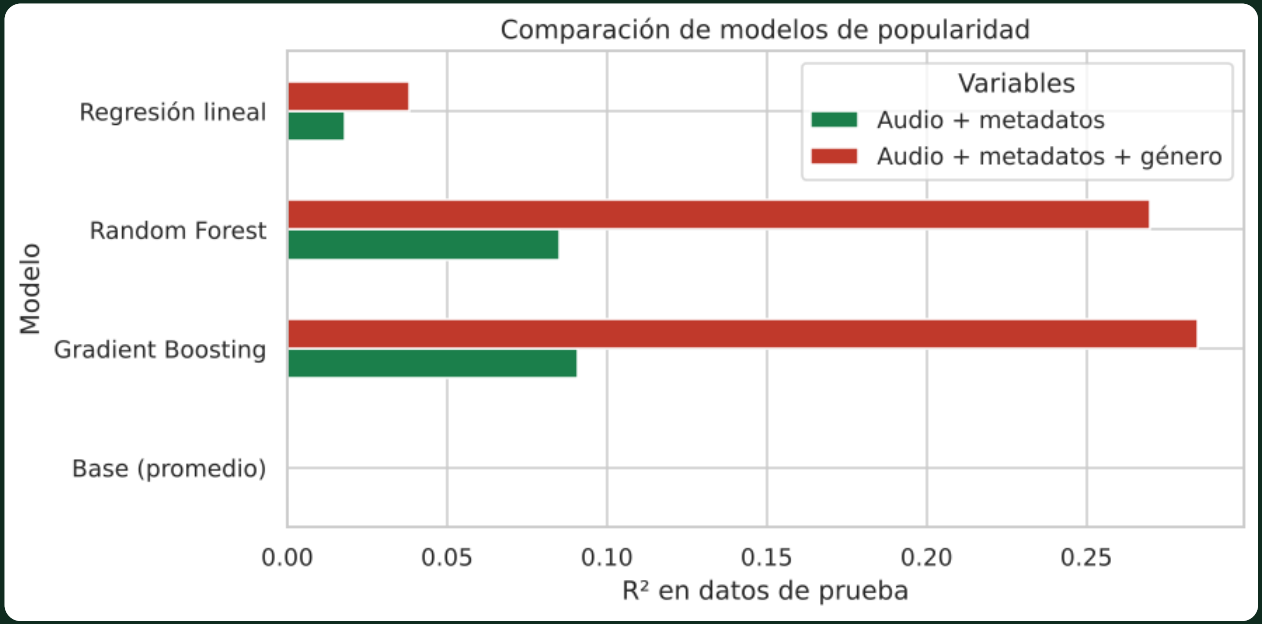
Suave y acústico · 23.1%

Instrumental y ambiental · 8.1%

Hablado · 1.2%

Silueta de 0.179: grupos con traslape, pero interpretables.

Análisis 2: la popularidad casi no se predice



$R^2 = 0.091$

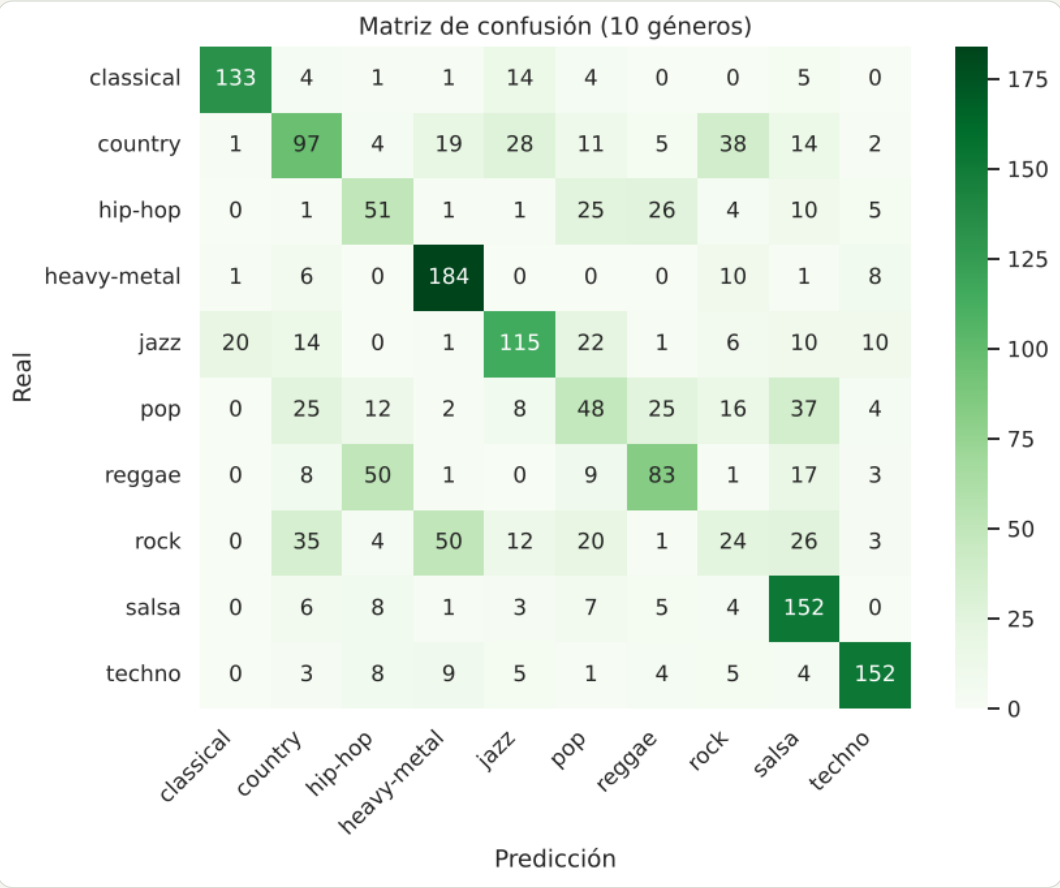
con audio y metadatos (mejor modelo)

$R^2 = 0.285$

al agregar el género

El error promedio baja de 18.8 puntos (modelo base) a 17.1 con audio y a 13.95 con género. Para predecir el éxito hacen falta datos de fuera del audio.

Análisis 3: el sonido reconoce algunos géneros



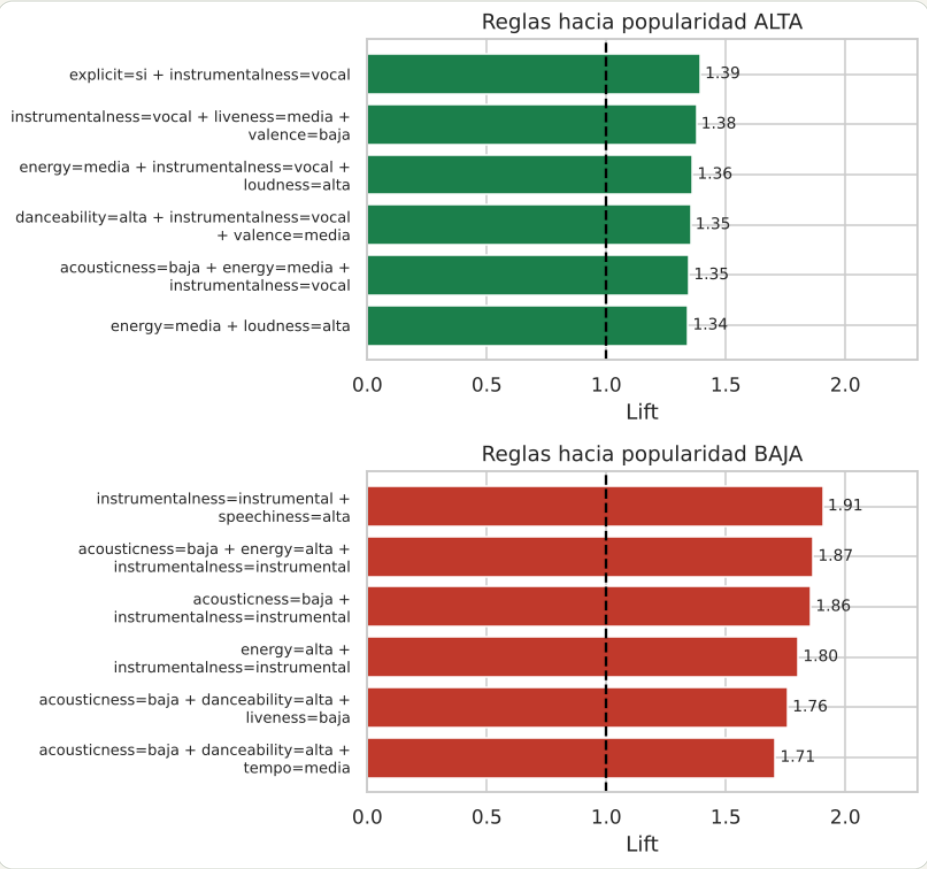
112 géneros (Random Forest): 26.9% de accuracy, contra 0.9% del azar; 45.0% si se aceptan los 3 más probables.

10 géneros: Random Forest 57.2% y SVM 53.3%.

Se reconocen bien **classical** (F1 0.84), **techno** (0.80) y **heavy-metal** (0.77).

Se confunden **rock** (0.17), **pop** (0.30) e **hip-hop** (0.39).

Análisis 4: reglas de asociación (Apriori)



Variables convertidas a niveles (baja, media, alta); soporte mínimo de 0.02. **281 reglas** hacia popularidad alta y **226** hacia baja.

Hacia popularidad alta (lift máx. 1.39): letra explícita y con voz; confianza de 35.0% contra 25.1% base.

Hacia popularidad baja (lift máx. 1.91): instrumental y con mucho habla; confianza de 49.0%.

Ninguna combinación de audio garantiza el éxito.

Resultados

Análisis	Resultado principal
1. Segmentación	5 segmentos interpretables; silueta 0.179
2. Popularidad	R^2 0.091 con audio; 0.285 con género
3. Género	26.9% con 112 géneros; 57.2% con 10 géneros
4. Asociación	Lift máximo de 1.39 (alta) y 1.91 (baja)

El audio sirve para **describir y organizar** un catálogo, pero no para predecir el éxito de una canción.

Cómo aprovecharlo y conclusiones

Aplicaciones

Listas automáticas por tipo de sonido, recomendar canciones nuevas sin historial y etiquetar géneros de forma automática.

Limitación

La popularidad depende de factores que no están en el audio: artista, promoción y comportamiento de los usuarios.

Siguientes pasos

Agregar datos del artista y de uso, probar XGBoost, otros algoritmos de agrupamiento y FP-Growth.

Gracias

Luis Aguilar · Yael García · Natalíe González · Axel Verastegui · Jaime Zermeño